

Lern-Nugget: Sigmoid als Spezialfall von Softmax

Ziel

Den eleganten Zusammenhang zwischen Sigmoid und Softmax verstehen - warum Sigmoid nur ein Spezialfall von Softmax für binäre Klassifikation ist!

Das Problem: Zwei scheinbar verschiedene Funktionen

Sigmoid (binäre Klassifikation):

- $\sigma(z) = 1/(1 + e^{(-z)})$
- Ausgabe: Eine Wahrscheinlichkeit zwischen 0 und 1
- Verwendung: "Hund oder Katze?", "Spam oder nicht?"

Softmax (Multi-Klassen-Klassifikation):

- $\text{softmax}(z_i) = e^{(z_i)} / \sum(e^{(z_j)})$
- Ausgabe: Wahrscheinlichkeitsverteilung über alle Klassen
- Verwendung: "Hund, Katze, oder Vogel?", "0, 1, 2, ..., 9?"

Frage: Sind das wirklich verschiedene Funktionen? 

Der Schlüssel: Softmax mit 2 Klassen

Gegeben: Zwei Klassen mit Logits z_1 und z_2

Softmax berechnen:

- $P(\text{Klasse 1}) = e^{(z_1)} / (e^{(z_1)} + e^{(z_2)})$
- $P(\text{Klasse 2}) = e^{(z_2)} / (e^{(z_1)} + e^{(z_2)})$

Schritt 1: Trick anwenden

Dividiere Zähler und Nenner durch $e^{(z_2)}$:

$$P(\text{Klasse 1}) = e^{(z_1)} / (e^{(z_1)} + e^{(z_2)}) = (e^{(z_1)}/e^{(z_2)}) / ((e^{(z_1)} + e^{(z_2)})/e^{(z_2)}) = e^{(z_1-z_2)} / (e^{(z_1-z_2)} + 1)$$

Definiere: $z = z_1 - z_2$ (der "relative" Logit)

$$P(\text{Klasse 1}) = e^z / (e^z + 1) = e^z / (e^z + 1) \cdot e^{(-z)}/e^{(-z)} = 1 / (1 + e^{(-z)})$$

Überraschung: Das ist Sigmoid!

$$P(\text{Klasse 1}) = \sigma(z_1 - z_2) = 1/(1 + e^{(-(z_1-z_2))})$$

Was bedeutet das?

1. **Sigmoid ist Softmax für 2 Klassen!**
2. **$z = z_1 - z_2$** ist der entscheidende "Unterschied" zwischen den Klassen

3. **P(Klasse 2) = 1 - P(Klasse 1)** automatisch erfüllt

Konkrete Zahlenbeispiele

Beispiel 1: Klare Entscheidung

Logits: $z_1 = 2, z_2 = -1$

- **Softmax:**
 - $P(\text{Klasse 1}) = e^2 / (e^2 + e^{-1}) = 7.39 / (7.39 + 0.37) \approx 0.95$
 - $P(\text{Klasse 2}) = e^{-1} / (e^2 + e^{-1}) = 0.37 / (7.39 + 0.37) \approx 0.05$
- **Sigmoid:** $\sigma(2 - (-1)) = \sigma(3) = 1 / (1 + e^{-3}) \approx 0.95 \checkmark$

Beispiel 2: Unklare Entscheidung

Logits: $z_1 = 0.5, z_2 = 0.3$

- **Softmax:**
 - $P(\text{Klasse 1}) = e^{0.5} / (e^{0.5} + e^{0.3}) = 1.65 / (1.65 + 1.35) \approx 0.55$
 - $P(\text{Klasse 2}) = e^{0.3} / (e^{0.5} + e^{0.3}) = 1.35 / (1.65 + 1.35) \approx 0.45$
- **Sigmoid:** $\sigma(0.5 - 0.3) = \sigma(0.2) = 1 / (1 + e^{-0.2}) \approx 0.55 \checkmark$

Intuitive Interpretation

Was sagt $z = z_1 - z_2$?

$z > 0$: Klasse 1 ist "stärker" $\rightarrow P(\text{Klasse 1}) > 0.5$ **$z < 0$:** Klasse 2 ist "stärker" $\rightarrow P(\text{Klasse 1}) < 0.5$

$z = 0$: Beide gleich stark $\rightarrow P(\text{Klasse 1}) = 0.5$

Praktische Bedeutung:

Bei binärer Klassifikation brauchen wir nur einen Logit!

- Statt z_1 und z_2 zu berechnen
- Berechnen wir direkt $z = \text{"Evidenz für Klasse 1 vs. Klasse 2"}$
- Sigmoid gibt uns $P(\text{Klasse 1}) = \sigma(z)$
- $P(\text{Klasse 2}) = 1 - \sigma(z)$ ergibt sich automatisch

Implementierung: Von Softmax zu Sigmoid

Multi-Klassen Netzwerk:

Input \rightarrow Hidden $\rightarrow [z_1, z_2, z_3, z_4] \rightarrow$ Softmax $\rightarrow [p_1, p_2, p_3, p_4]$

Binäres Netzwerk (ineffizient):

Input \rightarrow Hidden $\rightarrow [z_1, z_2] \rightarrow$ Softmax $\rightarrow [p_1, p_2]$

Binäres Netzwerk (elegant):

Input \rightarrow Hidden \rightarrow $z \rightarrow$ Sigmoid $\rightarrow p_1$
($p_2 = 1 - p_1$)

🎯 Wichtige Erkenntnisse

1. Mathematische Eleganz

- Sigmoid ist nicht "anders" als Softmax
- Es ist die **optimierte Version** für den 2-Klassen-Fall
- Ein Parameter weniger (z statt z_1, z_2)

2. Praktische Konsequenzen

- **Binäre Klassifikation:** Verwende Sigmoid (effizienter)
- **Multi-Klassen:** Verwende Softmax (notwendig)
- **Übergang:** Von binär zu multi-class ist nahtlos

3. Loss-Funktionen

- **Binary Cross-Entropy:** $-[y \log \sigma(z) + (1-y) \log(1-\sigma(z))]$
- **Categorical Cross-Entropy:** $-\sum y_i \log(\text{softmax}_i(z))$
- Für 2 Klassen sind beide **identisch!**

🎲 Übung: Verständnis testen

Gegeben: Ein Netzwerk klassifiziert E-Mails als "Spam" oder "Ham"

Szenario A: Zwei Output-Neuronen mit Softmax

- Output: $[2.1, -0.3] \rightarrow$ Softmax $\rightarrow [0.89, 0.11]$

Szenario B: Ein Output-Neuron mit Sigmoid

- Output: $z = ? \rightarrow$ Sigmoid $\rightarrow 0.89$

Frage: Welcher Wert z ergibt sich in Szenario B?

Lösung:

- $z = z_{\text{spam}} - z_{\text{ham}} = 2.1 - (-0.3) = 2.4$
- $\sigma(2.4) = 1/(1 + e^{(-2.4)}) \approx 0.89 \checkmark$

📄 Zusammenfassung

Kernbotschaft:

Sigmoid ist Softmax für 2 Klassen. Statt zwei Logits z_1, z_2 zu berechnen, berechnen wir einen "relativen" Logit $z = z_1 - z_2$ und wenden Sigmoid darauf an.

Praktisch bedeutet das:

- ☒ **Effizienz:** Ein Parameter weniger bei binärer Klassifikation
 - ☒ **Klarheit:** Der Output z hat direkte Interpretation (Evidenz-Unterschied)
 - ☒ **Flexibilität:** Nahtloser Übergang zwischen binär und multi-class
 - ☒ **Verständnis:** Beide Funktionen sind Teil derselben mathematischen Familie
-

💡 **Tipp:** Wenn Sie Sigmoid verstehen, verstehen Sie auch Softmax - und umgekehrt! Sie sind verschiedene Perspektiven auf dasselbe fundamentale Konzept der Wahrscheinlichkeitsmodellierung.